

Detecção e Segmentação de Copas de *Cecropia* (Embaúba) em Ortomosaico de VANT

Visão Computacional Clássica & Redes Neurais (SAM 3 + YOLOv8)

Grupo 10

Gabriel Arantes F. Gualda · Fábio H. A. Coelho · Nena A. Impanta
Augusto de H. V. Guerner · Eduardo G. de Lazari

INE5443 — Reconhecimento de Padrões
UFSC · Julho de 2026

Duas frentes complementares sobre o **mesmo** ortomosaico

- ▶ **Visão clássica:** HSV, morfologia, contornos e filtros geométricos.
- ▶ **SAM 3 e YOLOv8:** detecção e segmentação com modelos modernos.

Esta apresentação cobre as **duas frentes** para o mapeamento de copas de *Cecropia pachystachya* em ortomosaico de VANT do experimento MataDIV, e as compara ao final.

Problema Biológico e Objetivo

- ▶ Detectar e segmentar copas de *Cecropia pachystachya* em mosaico aéreo de alta resolução.
- ▶ Espécie pioneira, indicadora de regeneração, com copa umbeliforme distinta.
- ▶ Comparar uma abordagem **clássica** (regras de cor e forma) com uma **neural** (padrões aprendidos).
- ▶ Reduzir o esforço manual e os falsos positivos causados por vegetação de cor semelhante.

Área de Estudo e Ortomosaico (comum às duas frentes)

- ▶ Experimento **MataDIV** — Itatinga, SP (ESALQ/USP).
- ▶ 144 parcelas, ~ 8 ha, 6 espécies nativas + alta diversidade.
- ▶ Sobrevo: DJI Matrice 4T, 13/03/2026, 23 m de altitude.
- ▶ GSD $\approx 0,85$ cm/pixel.

Ortomosaico

48.264 $\times$ 47.029 px $\cdot$ 4 bandas (RGBA) $\cdot$ $\sim 8,46$ GB

SIRGAS 2000 / UTM 22S (EPSG:31982)

Parte I

Solução com Visão Computacional Clássica


Recorte e Amostras (Abordagem Clássica)

Parâmetro	Valor
Tiles	992 JPEGs de 2048×2048 px
CRS	EPSG:31982 (UTM Zona 22S)
Resolução espacial	$\approx 0,00848$ u/px
Tamanho em disco	899,0 MB
Tiles pretos ignorados	229
Tiles processados	361
Validação manual	35 tiles revisados

Motivação da Pipeline Clássica

- ▶ A embaúba apresenta copa com tonalidade verde-clara/amarelada no mosaico.
- ▶ A segmentação HSV gera candidatos por cor.
- ▶ A morfologia conecta fragmentos e remove ruído.
- ▶ Os contornos transformam a máscara em objetos mensuráveis.
- ▶ Filtros geométricos reduzem candidatos incompatíveis com copas plausíveis.

Visão Geral do Pipeline



Etapas do Pipeline

1. Gaussian Blur: kernel 9×9
2. Conversão BGR $\rightarrow$ HSV
3. Limiarização HSV: H[44,58] S[144,231] V[104,203]
4. Fechamento morfológico: elipse 25×25
5. Abertura morfológica: elipse 9×9
6. Detecção de contornos externos
7. Filtro de área mínima: área $> 10.000 \text{ px}^2$
8. Filtro final: área/circularidade + área máxima + solidez
9. Convex Hull para visualização e exportação

Filtro Final de Copa

Regra de decisão

Um candidato é aceito quando:

$$(\text{área} \geq 33.798 \text{ ou } \text{circularidade} \leq 0,1551)$$

e também:

$$\text{área} \leq 600.000 \quad \text{solidez} \geq 0,48$$


- ▶ Área/circularidade separa copas grandes ou irregulares.
- ▶ Área máxima remove blobs fundidos gigantes.
- ▶ Solidez remove regiões excessivamente fragmentadas.

Resultados Gerais

Métrica	Valor
Tiles processados	361
Tiles com detecção	311 (86,1%)
Total de detecções	1.218
Detecções por tile	$3,37 \pm 2,78$
Área total estimada	8.365,61 u ²
Área média por região	95.522 px ²
Área máxima por região	599.406 px ²
Cobertura HSV média	14,891%
Tempo total	89,0 s
Tempo médio por tile	$151,9 \pm 57,3$ ms


Distribuições Espaciais

Distribuição de Detecções por Tile




Detecções por tile

Distribuição das Áreas de Detecção




Áreas das detecções

Cobertura de Vegetação e Top 10



Cobertura HSV por tile




Top 10 por detecções


Métrica	Valor
Tiles revisados	35/35
Detecções avaliadas	146
Verdadeiros positivos (TP)	126
Falsos positivos (FP)	20
Falsos negativos / faltantes (FN)	50
Precisão	86,3%
Recall	71,6%
F1	78,3%

Alta precisão indica poucos falsos positivos na amostra revisada; o recall mostra que ainda há copas reais fora da saída final.

Desempenho Computacional



Tempo por tile



Memória por tile

Tempo médio de 151,9 ms/tile e memória próxima de 64 MB/tile.

Limitações da Abordagem Clássica

- ▶ Confusão espectral: outras espécies podem cair na mesma faixa HSV.
- ▶ Sensibilidade a iluminação e sombra.
- ▶ Possível fusão de copas próximas nas etapas morfológicas.
- ▶ Possível duplicação por sobreposição entre tiles.
- ▶ Recall limitado: parte das copas reais não vira candidato HSV ou é filtrada.

Parte II

Solução com Redes Neurais (SAM 3 + YOLOv8)

Motivação: SAM 3 e Curadoria por Exclusão

- ▶ **SAM 3** (Meta AI): modelo fundacional treinado em >1 bilhão de máscaras.
- ▶ Com *prompt* textual “tree”, segmenta apenas copas de árvores.
- ▶ **Curadoria por exclusão**: em vez de anotar do zero, o operador *remove* os segmentos que não são a espécie-alvo.
- ▶ Reduz drasticamente o esforço de anotação e a barreira de entrada do *deep learning*.

Pipeline Semi-automatizado em 6 Etapas

1. Geração do dataset com SAM 3 (*text prompt* “tree”) + curadoria.
2. Divisão espacial do dataset (evita *data leakage*).
3. Correção semi-automatizada das anotações.
4. Treinamento do YOLOv8x (otimização bayesiana).
5. Inferência e pós-processamento (duas rodadas + deduplicação).
6. Segmentação das copas novas com SAM 3 (*prompt* geométrico).

Etapa 1 — Geração do Dataset

- ▶ Ortomosaico recortado em tiles de 4.096 px (overlap 1.024) → SAM 3.
- ▶ 4.569 polígonos gerados → curadoria em QGIS → **1.109 máscaras** de *Cecropia*.
- ▶ *Bounding boxes* geradas automaticamente das máscaras (sem traçado manual).
- ▶ Tiles de treino de 896 px (overlap 50%): 1.109 indivíduos → **7.488 instâncias**.

As máscaras já servem de segmentação final para os 975 indivíduos dentro do MataDIV.

Etapas 2 e 3 — Divisão Espacial e Correção

- **Divisão espacial:** clusterização de tiles por grafo (BFS) + Monte Carlo (70/15/15) para evitar vazamento de dados.
- **Correção semi-automatizada:** modelo aponta detecções sem correspondência ($\text{IoU} < 0,5$), operador confirma copas reais não anotadas.

Conjunto	Imagens	Inst. (orig.)	Inst. (corr.)
Treinamento	776	6.300	6.300
Validação	167	543	687 (+144)
Teste	166	645	799 (+154)
Total	1.109	7.488	7.786

Etapa 4 — Treinamento do YOLOv8x

- ▶ Variante de maior capacidade (Ultralytics); só detecção — segmentação fica com o SAM 3.
- ▶ **Otimização bayesiana** (Optuna / TPE): 21 hiperparâmetros, 30 tentativas $\times$ 20 épocas.
- ▶ Três categorias: otimizador, pesos da perda e *data augmentation*.
- ▶ Importância dos hiperparâmetros via *Random Forest* (Mean Decrease Impurity).
- ▶ Treino final: 500 épocas, imagem 896 px, *batch* 8, AdamW.

Etapas 5 e 6 — Inferência e Segmentação

Inferência (pós-processamento)

- ▶ Duas rodadas (grade + offset 50%).
- ▶ Descarte de bordas e deduplicação.
- ▶ Filtros: confiança $\geq 0,65$; área 1,75–40 m².
- ▶ Cruzamento com máscaras SAM 3 (3 categorias).

Segmentação SAM 3 (*bbox prompt*)

- ▶ Recorte por *bbox* + *padding* 300 cm.
- ▶ SAM 3 gera máscara (seleção central).
- ▶ Área mínima 0,3 m²; confiança 0,25.
- ▶ Polígonos integrados ao mapa final.

Métricas e Resultados (Abordagem Neural)

Contagem final

- ▶ 144 parcelas; 60 com CP plantada.
- ▶ 2.256 CP plantadas.
- ▶ 1.226 CP mapeadas.
- ▶ Taxa global: 54,3%.
- ▶ 1.228 copas segmentadas.

Categorias

- ▶ YOLO + SAM 3: 564 (46,0%).
- ▶ Só YOLO: 267 (21,8%).
- ▶ Só SAM 3: 395 (32,2%).
- ▶ Área média: 5,55 m².
- ▶ Área mediana: 4,29 m².

Leitura por composição

Melhores taxas: D12 (68,3%), D7 (65,9%), D8 (65,7%) e D11 (62,7%). A D1 concentrou o maior desafio: 1.200 plantadas e 441 mapeadas (36,8%).

Pendente: métricas de teste do detector (P/R/F1, mAP50 e mAP50-95), curvas e figuras qualitativas.

Síntese

Comparação e Conclusões

Comparação das Duas Abordagens

Aspecto	Clássica (HSV)	Neural (SAM 3 + YOLOv8)
Sinal	Cor + forma	Padrões aprendidos
Anotação	Não requer	Curadoria por exclusão
Interpretabilidade	Alta	Baixa
Custo	Baixo (~152 ms/tile, CPU)	Alto (GPU, 500 épocas)
Segmentação	Fecho convexo	Máscara SAM 3
Discriminação	Fraca (espectral)	Potencialmente alta
Resultado	P 86,3 / R 71,6 / F1 78,3	1.226 mapeadas; 54,3% global

As frentes se complementam: a clássica como *baseline* interpretável; a neural buscando precisão e generalização.

Conclusões e Trabalhos Futuros

- ▶ O pipeline **clássico** é rápido, interpretável e adequado a uma primeira estimativa espacial: 1.218 regiões, 86,3% de precisão, 71,6% de recall.
- ▶ O pipeline **neural** reduz a anotação via SAM 3 e evita vazamento com divisão espacial; mapeou 1.226 indivíduos e segmentou 1.228 copas.
- ▶ **Próximos passos (clássica)**: refinar HSV, consolidar detecções entre tiles, testar descritores de textura.
- ▶ **Próximos passos (neural)**: incorporar P/R/F1 e mAP, revisar composições sem CP plantada e testar replicabilidade para outras espécies.
- ▶ **Integração**: clássica como pré-filtro rápido, neural como refinamento.