

1. INTRODUÇÃO

O conhecimento detalhado sobre árvores individuais, como sua identificação, distribuição espacial e desenvolvimento ao longo do tempo, constitui base fundamental para a pesquisa botânica, o manejo florestal e a conservação da biodiversidade (Wielgosz et al., 2024; Fassnacht et al., 2016). Essas informações permitem caracterizar a composição e a estrutura das comunidades vegetais, acompanhar a dinâmica florestal e subsidiar decisões práticas de manejo, além de avaliar a efetividade de ações de conservação e restauração (Langhammer et al., 2024; Soltani et al., 2025).

Tradicionalmente, essas informações são obtidas por meio de inventários realizados em campo. Embora fundamentais e eficazes, esses levantamentos apresentam desafios significativos: os custos elevados, a complexidade logística e a demanda por mão de obra especializada limitam a frequência e a escala em que podem ser conduzidos (Ferretti et al., 2024). Essa limitação torna-se ainda mais relevante diante do cenário global atual, no qual a Organização das Nações Unidas declarou o período de 2021 a 2030 como a Década da Restauração de Ecossistemas, com quase 60 países comprometidos a recuperar mais de 170 milhões de hectares até 2030 por meio do Desafio de Bonn (United Nations, 2019). A escala desses compromissos amplia a demanda por ferramentas que permitam acompanhar a evolução de áreas florestais de forma eficiente, tanto em projetos de restauração quanto na conservação de remanescentes nativos (De Almeida et al., 2020).

Nesse contexto, os Veículos Aéreos Não Tripulados (VANTs) têm se consolidado como ferramenta de alta relevância para o monitoramento florestal. A possibilidade de obter imagens com resolução espacial na ordem de centímetros viabiliza a observação de características morfológicas individuais das plantas, como formato e coloração das copas, padrões de ramificação e textura foliar, em um nível de detalhe inviável com imagens de satélite convencionais (Soltani et al., 2025; Sun et al., 2021). Essa resolução abre caminho para a detecção e o mapeamento de espécies arbóreas em nível individual, complementando os inventários de campo com uma cobertura espacial mais ampla e frequente.

Contudo, a disponibilidade de imagens de alta resolução, por si só, não resolve o problema do monitoramento em larga escala. A análise visual de ortomosaicos por especialistas torna-se inviável quando a área de estudo se amplia para dezenas ou centenas de hectares. Para superar essa limitação, técnicas de aprendizado profundo têm sido cada vez mais aplicadas ao processamento dessas imagens. As redes neurais convolucionais (CNNs) aprendem a reconhecer padrões visuais diretamente a partir dos exemplos fornecidos, sem que o pesquisador precise definir manualmente as características que distinguem uma espécie da outra, algo particularmente útil em ambientes florestais onde diferenças sutis entre copas tornam a definição de regras explícitas extremamente complexa (LeCun et al., 1998; Wagner et al., 2019). Essa capacidade tem viabilizado a detecção e a segmentação automatizada de copas em imagens aéreas, com resultados promissores para o mapeamento de espécies em diferentes biomas (Schiefer et al., 2020; Ferreira et al., 2020; Braga et al., 2020).

Apesar desses avanços, a aplicação prática de modelos supervisionados em contextos botânicos esbarra em um gargalo recorrente: a necessidade de grandes volumes

de dados de treinamento previamente anotados. Para que um modelo aprenda a diferenciar a espécie-alvo das demais, é preciso fornecer centenas ou milhares de exemplos rotulados, na forma de caixas delimitadoras (bounding boxes) marcando cada indivíduo ou máscaras de segmentação delineando cada copa pixel a pixel (Kattenborn et al., 2021). Em ambientes florestais, onde espécies morfológicamente semelhantes coexistem sob dosséis densos, essa tarefa é especialmente desafiadora e demanda conhecimento botânico especializado para cada anotação (Galuszynski et al., 2022). Em muitos casos, a anotação manual constitui a etapa mais demorada e custosa de todo o processo pelo grande esforço humano envolvido, representando a principal limitação para a adoção dessas técnicas em larga escala.

Avanços recentes em modelos fundacionais de segmentação oferecem uma alternativa promissora a esse cenário. O Segment Anything Model (SAM), desenvolvido pela Meta AI, **é um modelo fundacional, treinado em um conjunto de dados de mais de um bilhão de máscaras, capaz de segmentar objetos em imagens de domínios para os quais nunca foi especificamente treinado, como ortomosaicos de VANT em ambientes florestais (Kirillov et al., 2023).** Sua terceira versão, o SAM 3, introduziu uma funcionalidade particularmente relevante para a botânica e o sensoriamento remoto: a segmentação a partir de prompts textuais. **Diferentemente dos modelos de segmentação semântica convencionais, que classificam todos os pixels da imagem,** o SAM 3 com prompt textual segmenta apenas o que é solicitado pelo usuário. Ao receber a palavra "tree", por exemplo, o modelo delinea exclusivamente as copas de árvores presentes na imagem, ignorando os demais elementos da paisagem.

Essa funcionalidade permite repensar a forma como dados de treinamento são gerados para modelos supervisionados. Em vez de desenhar manualmente cada anotação, o pesquisador pode utilizar o SAM 3 para gerar candidatos de segmentação e, em seguida, realizar uma curadoria visual, removendo apenas os segmentos que não correspondem à espécie de interesse. Essa abordagem, denominada "curadoria por exclusão", inverte a lógica tradicional da anotação manual, uma vez que o esforço humano deixa de ser criar anotações do zero e passa a ser filtrar um conjunto pré-existente, tarefa significativamente mais rápida e que demanda apenas o reconhecimento da espécie-alvo.

Ao eliminar a necessidade de anotação manual e simplificar a criação de datasets supervisionados, essa abordagem torna o desenvolvimento de modelos de detecção e segmentação acessível a pesquisadores com conhecimento prévio de programação. Esse princípio dialoga com os fundamentos da ciência cidadã, na qual o engajamento de não-especialistas tem ampliado a capacidade de coleta e análise de dados ambientais em larga escala (Fraisl et al., 2022). A metodologia aqui apresentada compartilha desse espírito ao reduzir as barreiras técnicas, permitindo que botânicos, ecólogos, técnicos de restauração e gestores ambientais possam desenvolver e adaptar essas ferramentas a seus próprios contextos de trabalho.

Para o desenvolvimento e a avaliação dessa metodologia, a espécie *Cecropia pachystachya* Trécul (Urticaceae), popularmente conhecida como embaúba, foi selecionada como espécie alvo da pesquisa. As embaúbas são árvores pioneiras de rápido crescimento, amplamente distribuídas nas florestas tropicais e subtropicais da região Neotropical (Berg et al., 2005). Ecologicamente, desempenham papel relevante na dinâmica florestal, uma vez

que colonizam rapidamente clareiras e áreas perturbadas, atuam como facilitadoras dos estágios iniciais da sucessão ecológica e mantêm relações mutualísticas com formigas do gênero *Azteca*, que habitam seus caules ocos e contribuem para a defesa da planta contra herbívoros (De Oliveira et al., 2015). Sua presença e abundância estão associadas à intensidade de perturbações florestais, característica que as estabelece como indicadoras do estágio de regeneração de uma área (Guitet et al., 2018; Zalamea et al., 2012). Além de sua importância ecológica, *C. pachystachya* apresenta características morfológicas que favorecem sua detecção em imagens aéreas, como folhas grandes, palmatilobadas, com coloração verde-prateada na face abaxial, e copa de arquitetura umbeliforme distinta das demais espécies do dossel (Carvalho, 2008; Wagner et al., 2019). A conjunção entre relevância ecológica e distinguibilidade visual motivou sua escolha como modelo biológico para este estudo.

O estudo foi conduzido no experimento MataDIV (Mata Atlântica Diversidade), um experimento de larga escala de biodiversidade e funcionamento ecossistêmico (BEF) localizado na Estação Experimental de Itatinga (ESALQ/USP), São Paulo. O MataDIV manipula a riqueza de espécies em 144 parcelas com diferentes composições, desde monoculturas até misturas de 20 espécies nativas, proporcionando um cenário diversificado para avaliar o desempenho da metodologia sob diferentes condições de complexidade do dossel.

Com base no cenário descrito ao longo desta introdução, o presente trabalho propõe uma metodologia que integra o SAM 3 e técnicas de aprendizado profundo para o mapeamento de copas arbóreas em ortomosaicos de VANT, tendo *Cecropia pachystachya* como espécie alvo no experimento MataDIV. A investigação é orientada pela seguinte questão: é viável construir um pipeline de detecção e segmentação de copas arbóreas a partir de ortomosaicos de VANT, utilizando o SAM 3, com poucas etapas manuais e que seja replicável para diferentes espécies arbóreas?

2. OBJETIVOS

2.1. Objetivos gerais

Desenvolver e avaliar uma metodologia para detecção e segmentação individual de copas de *Cecropia pachystachya* em ortomosaico de VANT, integrando o SAM 3 e o YOLOv8, com ênfase na redução do esforço manual.

2.2. Objetivos Específicos

- Desenvolver um pipeline semi-automatizado de detecção e segmentação de copas arbóreas utilizando o SAM 3, com o menor número possível de etapas manuais no processo de criação do dataset e treinamento do modelo.
- Avaliar o desempenho do pipeline na detecção e segmentação de copas de *C. pachystachya* em diferentes cenários de composição florestal no experimento MataDIV.

- Discutir a replicabilidade do pipeline para a detecção e segmentação de outras espécies arbóreas.

3. MATERIAIS E MÉTODOS

3.1 Área de estudo

O estudo foi conduzido no experimento MataDIV (Mata Atlântica Diversidade), localizado na Estação Experimental de Ciências Florestais de Itatinga, pertencente à Escola Superior de Agricultura "Luiz de Queiroz" (ESALQ/USP), no município de Itatinga, estado de São Paulo, Brasil (23°06'S, 48°39'W, Figura X). O MataDIV é um experimento de diversidade arbórea e funcionamento ecossistêmico que integra a rede global TreeDivNet, voltada à investigação da relação entre diversidade de espécies arbóreas e funcionamento de ecossistemas florestais (Verheyen et al., 2016; Paquette et al., 2018). O experimento foi plantado em novembro e dezembro de 2019, em uma área de antigo talhão comercial de Eucalyptus, resultando de colaboração entre o Laboratório de Silvicultura Tropical (LASTROP) da ESALQ/USP e o CIRAD (Centre de Coopération Internationale en Recherche Agronomique pour le Développement, França).

[FIGURA X — Mapa de localização: Brasil, São Paulo, Itatinga, MataDIV]

O MataDIV tem como objetivo central compreender o funcionamento de florestas restauradas no bioma Mata Atlântica sob cenários de mudanças climáticas, fornecendo bases científicas para o delineamento de estratégias de restauração florestal (TreeDivNet, 2024). Para isso, o experimento manipula três variáveis: (i) riqueza de espécies, (ii) fertilização e (iii) disponibilidade hídrica, distribuídas em 144 parcelas experimentais que ocupam aproximadamente 8 hectares. Cada parcela possui dimensões de 20 m × 23 m e contém 100 árvores plantadas em espaçamento de 2,3 m, totalizando cerca de 14.400 indivíduos.

O experimento concentra-se em seis espécies nativas de ampla distribuição na Mata Atlântica, selecionadas por representarem estratégias ecológicas contrastantes: *Cecropia pachystachya* e *Guazuma ulmifolia*, espécies pioneiras de crescimento rápido, *Hymenaea courbaril* e *Cariniana estrellensis*, espécies de crescimento lento e estágio sucessional tardio, *Handroanthus impetiginosus*, de estratégia intermediária, e *Syagrus romanzoffiana*, uma palmeira. Essas espécies são combinadas em 12 estratos distintos: seis monoculturas, quatro misturas de três espécies, uma mistura de seis espécies e uma composição de alta diversidade com 20 espécies nativas como referência (Tabela 1). A *Cecropia pachystachya* está presente em cinco dessas composições, com densidade que varia de 100 indivíduos por parcela na monocultura a aproximadamente 5 indivíduos nas parcelas de alta diversidade.

[TABELA 1 — Composições de espécies no experimento MataDIV]

Essa variedade de composições torna o MataDIV uma área particularmente adequada para avaliar o desempenho de metodologias de detecção e segmentação de copas arbóreas, uma vez que permite testar a robustez do pipeline proposto sob diferentes condições de complexidade do dossel, desde monoculturas densas onde copas adjacentes se sobrepõem até misturas diversas onde as copas de *Cecropia* encontram-se intercaladas com espécies de morfologia e porte distintos.

3.2 Coleta de dados

A atividade de campo teve como finalidade a obtenção de imagens aéreas de altíssima resolução espacial da área do experimento MataDIV para geração de um ortomosaico georreferenciado. O voo foi planejado para o período de maior atividade vegetativa das espécies presentes no experimento, de modo a garantir que os indivíduos de *Cecropia pachystachya* apresentassem folhagem plena e suas copas fossem visualmente distinguíveis nas imagens. Uma primeira campanha de campo, realizada no meio de 2025, encontrou a vegetação sem folhagem, inviabilizando a aplicação da metodologia. Foi necessário aguardar o período de chuvas para retornar a campo.

O sobrevoo foi realizado no dia 13 de março de 2026 utilizando o VANT DJI Matrice 4T, equipado com câmera RGB wide (sensor CMOS 1/1.3 polegada, 48 MP, distância focal equivalente 24 mm, campo de visão de 82 graus). A coleta das imagens foi realizada a uma altitude de 23 m acima do nível do solo, com sobreposição frontal e lateral de 80%, resultando em uma resolução espacial no solo (GSD) de aproximadamente 0,85 cm/pixel. Esse nível de detalhe permite a observação de características morfológicas individuais das copas, como formato, textura foliar e coloração, requisito fundamental para a etapa de detecção e segmentação proposta neste trabalho.

As imagens obtidas foram processadas por meio de fotogrametria digital utilizando o software Agisoft Metashape para geração do ortomosaico georreferenciado. O ortomosaico resultante possui dimensões de 48.264 × 47.029 pixels, com quatro bandas espectrais (R, G, B e alfa), totalizando aproximadamente 8,46 GB em formato GeoTIFF, projetado no sistema de referência SIRGAS 2000 / UTM zona 22S (EPSG:31982).

3.3 Métodos

A metodologia proposta é composta por seis etapas sequenciais, organizadas em um pipeline semi-automatizado que integra o SAM 3 e o YOLOv8 para a detecção e segmentação de copas de *Cecropia pachystachya* (Figura X). Na primeira etapa, o SAM 3 com prompt textual segmenta automaticamente as copas de árvores no ortomosaico, e o operador realiza a curadoria por exclusão para reter apenas a espécie-alvo, gerando o dataset de treinamento. Na segunda etapa, o dataset é dividido em conjuntos de treinamento, validação e teste por meio de clusterização espacial para evitar vazamento de dados. A terceira etapa consiste na correção semi-automatizada das anotações nos conjuntos de validação e teste. Na quarta etapa, o modelo YOLOv8x é treinado com otimização bayesiana dos hiperparâmetros. Na quinta etapa, o modelo treinado é aplicado

sobre o ortomosaico completo para detecção dos indivíduos, seguida de pós-processamento para remoção de duplicatas e filtragem de detecções espúrias. Por fim, na sexta etapa, os indivíduos detectados exclusivamente pelo YOLO recebem segmentação de copa por meio do SAM 3 com prompt geométrico.

[FIGURA X — Fluxograma geral do pipeline semi-automatizado, ilustrando as seis etapas da metodologia: (1) geração do dataset com SAM 3 text prompt, (2) divisão espacial, (3) correção das anotações, (4) treinamento YOLOv8x, (5) inferência e pós-processamento, (6) segmentação com SAM 3 bbox prompt]

A espécie-alvo deste estudo, *Cecropia pachystachya*, apresenta copa de formato umbeliforme com folhas palmatilobadas de coloração verde-prateada que a tornam visualmente distinta das demais espécies no ortomosaico (Figura X). Essa distinção é perceptível mesmo em áreas de mistura com outras espécies, embora em parcelas de monocultura as copas adjacentes tendam a se sobrepor, dificultando a individualização.

[FIGURA X — Exemplos de copas de *C. pachystachya* no ortomosaico: (a) copa isolada em parcela de mistura, (b) copas adjacentes em parcela de monocultura, (c) copa jovem de menor porte]

3.3.1 Geração do dataset de treinamento

A geração do dataset de treinamento constitui a primeira etapa da metodologia proposta, uma vez que substitui o processo convencional de anotação manual por uma abordagem semi-automatizada baseada no SAM 3. Enquanto abordagens tradicionais demandam que o pesquisador desenhe manualmente caixas delimitadoras ou máscaras de segmentação para cada indivíduo arbóreo, o fluxo aqui adotado utiliza o SAM 3 com prompt textual para gerar automaticamente candidatos de segmentação, reduzindo o esforço humano a uma etapa de curadoria visual.

O ortomosaico georreferenciado foi recortado em tiles de 4.096×4.096 pixels com sobreposição de 1.024 pixels e submetido ao SAM 3 com o prompt textual "tree". O modelo segmentou automaticamente as copas de árvores presentes em cada tile, gerando um total de 4.569 polígonos de segmentação referentes a diversas espécies arbóreas. Como a área coberta pelo ortomosaico ultrapassa os limites do experimento MataDIV, parte dos polígonos gerados corresponde a indivíduos localizados no entorno da área experimental.

Os polígonos gerados pelo SAM 3 foram carregados no ambiente SIG (QGIS), onde o operador realizou a curadoria por exclusão: cada polígono foi avaliado visualmente e aqueles que não correspondiam a indivíduos de *Cecropia pachystachya* foram removidos. Ao final desse processo, restaram 1.109 máscaras de segmentação da espécie-alvo, das quais 975 estavam localizadas dentro dos limites do MataDIV e 134 no entorno da área experimental. Essa etapa demandou apenas o reconhecimento visual da espécie, sem a necessidade de desenhar qualquer anotação. A partir das máscaras curadas, caixas delimitadoras (bounding boxes) foram geradas automaticamente no QGIS por meio da ferramenta de geometria envolvente, sem intervenção manual no traçado dos retângulos.

As máscaras geradas nessa etapa cumprem uma dupla função no pipeline: servem como base para a criação do dataset de treinamento do modelo de detecção (por meio dos bounding boxes extraídos) e, simultaneamente, constituem o produto final de segmentação para os indivíduos identificados nessa fase. As 975 cecropias segmentadas pelo SAM 3 dentro do MataDIV já possuem suas copas delineadas e não necessitam de segmentação adicional.

Para o treinamento do modelo de detecção, o ortomosaico foi recortado em tiles de 896×896 pixels com sobreposição de 50%. O tamanho do tile foi definido com base na maior copa de *Cecropia pachystachya* identificada na área de estudo, garantindo que nenhum tile fosse menor que a dimensão de uma copa inteira e que o modelo recebesse contexto espacial suficiente para cada indivíduo durante o treinamento. A sobreposição de 50% faz com que um mesmo indivíduo apareça em múltiplos tiles e em posições relativas distintas dentro de cada tile, funcionando como uma forma implícita de aumento de dados (data augmentation) que contribui para a capacidade de generalização do modelo.

Dessa forma, os 1.109 indivíduos únicos geraram 7.488 instâncias de treinamento, correspondendo a um fator de repetição médio de 6,8 vezes por indivíduo. As coordenadas dos polígonos das copas foram convertidas em arquivos de anotação no formato YOLO, com as coordenadas dos vértices normalizadas entre 0 e 1 em relação às dimensões de cada tile.

3.3.2 Divisão espacial do dataset

Com as anotações estruturadas no formato adequado, o passo seguinte consistiu na divisão do dataset em conjuntos de treinamento (70%), validação (15%) e teste (15%). Essa divisão não foi realizada por amostragem aleatória simples. Em imagens de sensoriamento remoto com sobreposição entre tiles, a separação aleatória pode resultar em vazamento de dados (data leakage), situação na qual um mesmo indivíduo arbóreo aparece simultaneamente nos conjuntos de treinamento e teste, inflando artificialmente as métricas de desempenho do modelo (Roberts et al., 2017; Kattenborn et al., 2022). Para evitar esse problema, foi implementado um algoritmo de divisão baseado em clusterização espacial.

O algoritmo opera em quatro etapas. Na primeira, cada anotação é associada ao tile cujo centroide está mais próximo, estabelecendo uma relação unívoca entre anotação e tile. Na segunda etapa, o algoritmo identifica anotações que intersectam mais de um tile com sobreposição superior a 20% da área da anotação. Quando isso ocorre, os tiles envolvidos são vinculados, pois compartilham o mesmo indivíduo e não podem ser separados em conjuntos distintos. Na terceira etapa, os vínculos entre tiles formam um grafo, no qual componentes conexos são identificados por busca em largura (BFS), definindo clusters de tiles que devem obrigatoriamente pertencer ao mesmo conjunto. Por fim, os clusters são distribuídos entre treinamento, validação e teste por meio de otimização estocástica de Monte Carlo, com 1.000 iterações, minimizando o erro quadrático médio (MSE) entre as proporções obtidas e as metas de 70/15/15 para cada classe.

3.3.3 Correção semi-automatizada das anotações

Com o dataset dividido nos conjuntos de treinamento, validação e teste, o modelo foi submetido a um primeiro ciclo de treinamento e avaliação (descrito na seção 3.3.4). A análise da matriz de confusão desse treinamento inicial revelou que parte dos falsos negativos correspondia a indivíduos reais de *Cecropia pachystachya* presentes nas imagens, porém ausentes nas anotações originais geradas pelo SAM 3. Para corrigir essa limitação, foi desenvolvido um procedimento semi-automatizado de verificação e complementação das anotações nos conjuntos de validação e teste.

O modelo treinado foi aplicado sobre as imagens dos conjuntos de validação e teste, e cada detecção foi comparada com as anotações existentes por meio da Intersecção sobre União (IoU). Detecções com IoU inferior a 0,5 em relação a qualquer anotação existente foram consideradas potenciais indivíduos não anotados. Para cada imagem contendo detecções sem correspondência, foi gerada uma visualização com as anotações existentes destacadas em verde e as detecções sem match em vermelho (Figura X), permitindo que o operador avaliasse visualmente cada caso.

[FIGURA X — Exemplo de imagem do conjunto de teste com anotações existentes (verde) e detecções sem correspondência (vermelho) identificadas pelo procedimento semi-automatizado]

No conjunto de teste, das 163 detecções sem correspondência, 157 foram confirmadas como cecropias genuínas e apenas 6 foram descartadas como falsos positivos. No conjunto de validação, 144 novas anotações foram incorporadas e 2 foram descartadas. Após o merge das novas anotações e a remoção dos caches de validação, o modelo foi retreinado com os conjuntos corrigidos.

A correção foi aplicada apenas aos conjuntos de validação e teste por serem menores (aproximadamente 160 imagens cada), demandando um esforço de curadoria visual compatível com a proposta do pipeline. Se o pesquisador dispuser de mais tempo, o mesmo procedimento pode ser estendido ao conjunto de treinamento (776 imagens), potencialmente melhorando ainda mais as métricas do modelo.

Com as correções, o conjunto de validação passou de 543 para 687 instâncias e o conjunto de teste de 645 para 799 instâncias. O dataset final ficou constituído da seguinte forma (Tabela 2):

[TABELA 2 — Estrutura final do dataset]

Conjunto	Imagens	Instâncias (original)	Instâncias (corrigido)
Treinamento	776	6.300	6.300 (sem alteração)
Validação	167	543	687 (+144)
Teste	166	645	799 (+154)
Total	1.109	7.488	7.786

3.3.4 Treinamento do modelo de detecção

A etapa de detecção dos indivíduos de *Cecropia pachystachya* foi conduzida com o modelo YOLOv8x, a variante de maior capacidade da família YOLOv8, implementada por

meio da biblioteca Ultralytics em Python (Jocher et al., 2023) . A escolha dessa variante se deve ao seu maior número de camadas e parâmetros treináveis, o que favorece a extração de padrões complexos em imagens de alta resolução espacial. Neste trabalho, utilizou-se a versão de detecção do YOLOv8x e não a de segmentação de instâncias, uma vez que o SAM 3 é responsável pela delimitação das copas nas etapas inicial e final do pipeline. Ao YOLO cabe exclusivamente a localização dos indivíduos por meio de caixas delimitadoras.

O desempenho de modelos de deep learning é sensível à configuração dos seus hiperparâmetros, e a exploração manual desse espaço torna-se inviável quando há dezenas de variáveis a serem ajustadas simultaneamente. Diante disso, optou-se por uma otimização bayesiana para automatizar a seleção dos melhores valores, utilizando o framework Optuna (Akiba et al., 2019) com o amostrador TPE (Tree-structured Parzen Estimator). Nessa abordagem, cada nova tentativa de treinamento é informada pelos resultados das tentativas anteriores, o que direciona a busca para combinações de hiperparâmetros progressivamente mais promissoras.

O espaço de busca contemplou 21 hiperparâmetros, agrupados em três categorias. A primeira reúne os parâmetros do otimizador, responsáveis por regular a dinâmica de aprendizado da rede (taxa de aprendizado, momentum, weight decay, warmup epochs e freeze layers). A segunda categoria corresponde aos pesos da função de perda, que definem a importância relativa de cada componente do erro durante o treinamento (box loss weight e class loss weight). A terceira abrange os parâmetros de aumento de dados (data augmentation), que introduzem variações nas imagens de treinamento por meio de transformações geométricas e ajustes de cor, ampliando a diversidade do conjunto sem a necessidade de coletar novas amostras (Tabela X).

[TABELA X — Espaço de busca dos hiperparâmetros otimizados]

Categoria: Hiperparâmetros do otimizador				
Hiperparâmetro		Funcionalidade	Limite Inferior	Limite Superior
21 1,0 0,001 5	Freeze Layers	Número de camadas sem atualização de pesos	0	
	Learning Rate (lr0)	Taxa de aprendizagem inicial	1e-05	0,01
	Final LR Factor (lrf)	Fator de decaimento final do learning rate	0,01	
	Momentum	Inércia do otimizador	0,6	0,98
	Weight Decay	Penaliza pesos grandes para evitar overfitting		0,0001
	Warmup Epochs	Épocas iniciais com learning rate crescente	0	
	Categoria: Pesos da função de perda			
Hiperparâmetro		Funcionalidade	Limite Inferior	Limite Superior
0,2	Box Loss Weight	Peso da perda de localização da bounding box		0,02
	Class Loss Weight	Peso da perda de classificação	0,2	4,0

Categoria: Parâmetros de aumento de dados (data augmentation)				
Hiperparâmetro	Funcionalidade	Limite Inferior Limite Superior		
HSV Hue Aug.	Alteração da tonalidade da imagem	0	0,1	
HSV Sat. Aug.	Alteração da saturação da imagem	0	0,9	
HSV Val. Aug.	Alteração do brilho da imagem	0	0,9	
Rotation (deg)	Transformação geométrica de rotação	0	45	
Translation	Transformação geométrica de translação	0	0,9	
Scale Aug.	Transformação geométrica de escala	0	0,9	
Shear (deg)	Transformação geométrica de cisalhamento	0		
10				
Perspective	Transformação geométrica de perspectiva	0		
0,001				
Flip Up-Down	Espelhamento vertical da imagem	0	1	
Flip Left-Right	Espelhamento horizontal da imagem	0	1	
Mosaic	Combinação de 4 imagens em 1	0	1	
MixUp	Sobreposição de duas imagens com transparência			0
1				
Copy-Paste	Cópia de segmentos de uma imagem para outra			0
1				

O espaço de busca foi composto pelos hiperparâmetros que exercem maior influência sobre o comportamento do YOLOv8 durante o treinamento. Dentre eles, os parâmetros de data augmentation desempenham papel importante na robustez do modelo, pois introduzem variações controladas nas imagens, como rotações, mudanças de escala e combinações de tiles (mosaic, mixup), ampliando a variabilidade dos dados sem a necessidade de novas anotações. Os limites inferior e superior de cada hiperparâmetro foram definidos conforme os valores padrão da biblioteca Ultralytics. A otimização foi conduzida ao longo de 30 tentativas com 20 épocas de treinamento cada, utilizando o mAP50 (mean Average Precision com IoU de 0,5) avaliado no conjunto de validação como métrica de orientação da busca. Para o treinamento durante a otimização, foi utilizado um batch size de 8 e tamanho de imagem de 896 × 896 pixels.

Além da seleção dos melhores hiperparâmetros, buscou-se compreender quais variáveis exerceram maior influência sobre o desempenho do modelo. Para isso, os resultados das 30 tentativas foram utilizados como dados de entrada para um regressor Random Forest composto por 500 árvores de decisão, capaz de capturar relações não-lineares entre os hiperparâmetros e o mAP50 obtido. A contribuição de cada hiperparâmetro foi estimada pela Redução Média da Impureza (Mean Decrease Impurity), métrica que registra, ao longo de todas as árvores, o quanto cada variável contribui para a redução da variância nos nós de decisão. Os valores de importância foram normalizados para que a soma total seja igual a 1,0.

Concluída a otimização, o treinamento final do modelo foi realizado com 500 épocas, tamanho de imagem de 896 pixels, batch size de 8 e otimizador AdamW, adotando os valores dos hiperparâmetros obtidos pela tentativa que apresentou o melhor desempenho.

3.3.5 Inferência e pós-processamento

Com o modelo treinado e avaliado, a etapa seguinte consistiu em aplicá-lo sobre o ortomosaico completo para detecção dos indivíduos de *Cecropia pachystachya*. O ortomosaico foi recortado em tiles de 896×896 pixels com sobreposição de 50%, utilizando o mesmo tamanho de tile adotado no treinamento. Para garantir que indivíduos localizados nas bordas entre tiles fossem detectados adequadamente, a inferência foi conduzida em duas rodadas: uma com os tiles na grade regular e outra com tiles deslocados em meio passo (offset de 50%), de modo que regiões de borda na primeira rodada ficassem centralizadas nos tiles da segunda (Figura X).

[FIGURA X — Esquema das duas rodadas de inferência: tiles na grade regular (esquerda) e tiles deslocados em meio passo (direita), ilustrando como a segunda rodada cobre as regiões de borda da primeira]

Detecções localizadas dentro de uma margem de 10 pixels da borda do tile foram descartadas, uma vez que representam indivíduos parcialmente visíveis que tendem a ser detectados de forma mais completa em tiles adjacentes. Em seguida, as detecções das duas rodadas foram combinadas e submetidas a um procedimento de remoção de duplicatas, no qual pares de detecções com sobreposição espacial superior a 10% da menor área entre elas foram identificados. Em cada par duplicado, a detecção com menor confiança foi descartada, preservando apenas a de maior confiança. Esse procedimento foi aplicado tanto entre as detecções das duas rodadas quanto internamente ao conjunto combinado.

Após a remoção de duplicatas, foram aplicadas regras de filtragem para exclusão de detecções espúrias. Detecções com confiança inferior a 0,65 foram descartadas, assim como detecções com área inferior a $1,75 \text{ m}^2$ ou superior a 40 m^2 , valores definidos com base nas dimensões conhecidas das copas de *Cecropia pachystachya* na área de estudo. Detecções localizadas fora dos limites da área experimental do MataDIV também foram excluídas.

As detecções resultantes foram então cruzadas espacialmente com as máscaras de segmentação geradas pelo SAM 3 na etapa de geração do dataset (seção 3.3.1), permitindo classificar os indivíduos mapeados em três categorias: (i) indivíduos detectados pelo YOLO que já possuíam máscara de segmentação proveniente da etapa inicial, (ii) indivíduos detectados exclusivamente pelo YOLO, sem máscara prévia, e (iii) indivíduos segmentados pelo SAM 3 na etapa inicial que não foram detectados pelo YOLO durante a inferência (Figura X).

[FIGURA X — Fluxograma do cruzamento espacial entre detecções YOLO e máscaras SAM 3, ilustrando as três categorias de indivíduos resultantes]

Os indivíduos da primeira e da terceira categoria já dispõem de segmentação de copa proveniente da etapa inicial e não necessitam de processamento adicional. Os indivíduos da segunda categoria, por serem detecções novas sem máscara prévia, foram encaminhados para a etapa de segmentação refinada descrita na seção 3.3.6.

3.3.6 Segmentação das copas com SAM 3 por prompt geométrico

Os indivíduos detectados exclusivamente pelo YOLO durante a inferência não possuem máscara de segmentação proveniente da etapa inicial, uma vez que não haviam sido identificados pelo SAM 3 com prompt textual. Para segmentar as copas desses indivíduos, utilizou-se novamente o SAM 3, agora com prompt geométrico, no qual a bounding box detectada pelo YOLO é fornecida como entrada para orientar a segmentação.

O procedimento consiste em recortar do ortomosaico uma região ao redor de cada bounding box, com uma margem de expansão (padding) que fornece contexto espacial suficiente para que o SAM 3 delimite a copa adequadamente. O recorte georreferenciado é então submetido ao SAM 3, que gera uma ou mais máscaras candidatas para a região indicada pela bounding box (Figura X). Quando o modelo produz múltiplas máscaras candidatas, adota-se um critério de seleção central, no qual a máscara cujo centroide está mais próximo do centro do recorte é selecionada como segmentação final. Após a seleção, as máscaras são convertidas em polígonos vetoriais georreferenciados e submetidas a operações de limpeza morfológica para remoção de pequenos artefatos.

[FIGURA X — Exemplo do processo de segmentação por prompt geométrico: (a) recorte do ortomosaico com bounding box do YOLO, (b) máscara gerada pelo SAM 3, (c) polígono vetorial resultante sobreposto ao ortomosaico]

O padding e o limiar de área mínima do polígono foram definidos experimentalmente, avaliando diferentes configurações a fim de maximizar a taxa de segmentações válidas e excluir fragmentos que não correspondem a copas reais. A configuração final adotada foi de 300 cm de padding, área mínima de 0,3 m² e confiança do SAM 3 de 0,25 (Tabela X).

[TABELA X — Parâmetros da segmentação por prompt geométrico com SAM 3]

Parâmetro	Valor adotado
Padding ao redor da bbox	300 cm
Área mínima do polígono	0,3 m ²
Confiança do SAM 3	0,25
Estratégia de seleção	Central (centroide mais próximo do centro)

Os polígonos resultantes dessa etapa foram então integrados ao conjunto de máscaras provenientes da segmentação inicial por prompt textual (seção 3.3.1), compondo o mapeamento final de copas de *Cecropia pachystachya* na área do experimento MataDIV. O desempenho de cada etapa do pipeline, assim como os resultados consolidados do mapeamento, são apresentados na seção seguinte.

3.3.7 Métricas de avaliação

O desempenho do modelo de detecção foi avaliado utilizando o conjunto de teste, composto por imagens e anotações que não participaram do treinamento nem da validação, constituindo dados independentes para mensurar a capacidade de generalização do detector. A avaliação consiste em comparar as detecções geradas com as anotações de referência, classificando cada detecção como Verdadeiro Positivo (VP), Falso Positivo (FP) ou Falso Negativo (FN).

Para que uma detecção seja considerada um Verdadeiro Positivo, é necessário que exista correspondência espacial entre a caixa delimitadora predita e a anotação de referência. Essa correspondência é medida pela Intersecção sobre União (IoU, do inglês Intersection over Union), definida como a razão entre a área de interseção e a área de união das duas caixas delimitadoras (Terven et al., 2023):

$$\text{IoU} = \text{Área da Interseção} / \text{Área da União}$$

O valor de IoU varia de 0 (nenhuma sobreposição) a 1 (sobreposição total). Neste trabalho, adotou-se o limiar de IoU igual a 0,5, de modo que detecções com IoU maior ou igual a esse valor foram classificadas como Verdadeiros Positivos, enquanto detecções sem correspondência foram classificadas como Falsos Positivos e anotações não detectadas como Falsos Negativos (Figura X).

[FIGURA X — Representação gráfica do cálculo de IoU entre a caixa predita e a caixa de referência, com exemplos de diferentes valores de IoU]

A partir da contagem de VP, FP e FN, foram calculadas as seguintes métricas:

A Precision (P) expressa a proporção de detecções corretas em relação ao total de detecções realizadas, refletindo a capacidade de evitar falsos positivos:

$$P = VP / (VP + FP)$$

O Recall (R), por sua vez, mede a proporção de indivíduos corretamente identificados em relação ao total de indivíduos presentes nas anotações de referência, indicando o quanto o detector é capaz de encontrar todos os indivíduos existentes na imagem:

$$R = VP / (VP + FN)$$

O F1-score corresponde à média harmônica entre Precision e Recall, fornecendo uma medida única que equilibra ambas as métricas:

$$F1 = 2 \times (P \times R) / (P + R)$$

A Average Precision (AP) é calculada como a área sob a curva Precision-Recall, que representa a variação da Precision em função do Recall para diferentes limiares de confiança:

$$AP = \text{integral de 0 a 1 de } P(R) \, dR$$

Em tarefas de detecção de objetos com múltiplas classes, o desempenho global do modelo é avaliado pelo mAP (mean Average Precision), que corresponde à média das APs calculadas individualmente para cada classe. No presente trabalho, como há apenas uma classe (*Cecropia pachystachya*), o mAP equivale à própria AP. Apesar dessa equivalência, optou-se por manter a notação mAP50 ao longo do trabalho por ser a terminologia padrão adotada pela biblioteca Ultralytics e pela literatura de detecção de objetos, facilitando a comparação direta com outros estudos (Terven et al., 2023). Para uma avaliação mais rigorosa da qualidade das detecções, utilizou-se também o mAP50-95, que calcula a média da AP em dez limiares de IoU igualmente espaçados entre 0,5 e 0,95 (0,50, 0,55, 0,60, ..., 0,95). Essa métrica penaliza detecções com baixa sobreposição espacial em relação às anotações de referência, exigindo maior precisão na localização das caixas delimitadoras.