

Detecção e Segmentação de Copas de *Cecropia* (Embaúba) em Ortomosaico de VANT

Duas abordagens: Visão Computacional Clássica e Redes Neurais (SAM 3 + YOLOv8)

INE5443 — Reconhecimento de Padrões
UFSC

Grupo 10

Gabriel Arantes F. Gualda Fábio H. A. Coelho Nena A. Impanta
Augusto de H. V. Guerner Eduardo G. de Lazari

Julho de 2026

Sumário

1	Introdução	3
2	Objetivos	4
3	Área de Estudo e Coleta de Dados	4
3.1	Área de estudo	4
3.2	Coleta de dados e ortomosaico	5
I	Solução com Visão Computacional Clássica	5
4	Dataset (Recorte para a Abordagem Clássica)	5
5	Pipeline de Detecção Clássico	6
5.1	Etapa 1 - Suavização (Gaussian Blur)	7
5.2	Etapa 2 - Conversão BGR → HSV	8
5.3	Etapa 3 - Limiarização por Cor	9
5.4	Etapa 4 - Fechamento Morfológico	10
5.5	Etapa 5 - Abertura Morfológica	11
5.6	Etapa 6 - Detecção de Contornos	12
5.7	Etapa 7 - Filtragem por Área Mínima	13
5.8	Etapa 8 - Filtro Final de Embaúba	14
5.9	Etapa 9 - Convex Hull	15
6	Resultados da Abordagem Clássica	15

6.1	Estatísticas Gerais	15
6.2	Distribuição de Detecções por Tile	16
6.3	Distribuição das Áreas de Detecção	17
6.4	Cobertura HSV por Tile	17
6.5	Top 10 Tiles com Mais Detecções	18
6.6	Validação Manual	18
6.7	Desempenho Computacional	19
7	Interpretação e Limitações da Abordagem Clássica	19
7.1	Alta taxa de tiles com detecções (86,1%)	19
7.2	Falsos positivos por confusão espectral	19
7.3	Regiões de área muito grande	20
7.4	Leitura da Validação	20
II	Solução com Redes Neurais (SAM 3 + YOLOv8)	20
8	Metodologia da Abordagem Neural	20
8.1	Contexto: SAM 3 e curadoria por exclusão	21
8.2	Geração do dataset de treinamento	21
8.3	Divisão espacial do dataset	22
8.4	Correção semi-automatizada das anotações	22
8.5	Treinamento do modelo de detecção	23
8.6	Inferência e pós-processamento	25
8.7	Segmentação das copas com SAM 3 por prompt geométrico	25
8.8	Métricas de avaliação	26
9	Resultados da Abordagem Neural	26
III	Síntese Comparativa	26
10	Discussão Comparativa	26
11	Conclusões	27

1 Introdução

O conhecimento detalhado sobre árvores individuais — sua identificação, distribuição espacial e desenvolvimento ao longo do tempo — constitui base fundamental para a pesquisa botânica, o manejo florestal e a conservação da biodiversidade (Wielgosz et al., 2024; Fasnacht et al., 2016). Tradicionalmente, essas informações são obtidas por inventários de campo que, embora eficazes, apresentam custos elevados, complexidade logística e demanda por mão de obra especializada, limitando a frequência e a escala em que podem ser conduzidos (Ferretti et al., 2024). Essa limitação torna-se ainda mais relevante diante do compromisso global da Década da Restauração de Ecossistemas (2021–2030), que amplia a demanda por ferramentas capazes de acompanhar a evolução de áreas florestais de forma eficiente (De Almeida et al., 2020).

Nesse contexto, os Veículos Aéreos Não Tripulados (VANTs) consolidaram-se como ferramenta de alta relevância para o monitoramento florestal. Imagens com resolução espacial na ordem de centímetros viabilizam a observação de características morfológicas individuais das plantas — formato e coloração das copas, padrões de ramificação e textura foliar — em nível de detalhe inviável com imagens de satélite convencionais (Soltani et al., 2025). Contudo, a disponibilidade de imagens de alta resolução, por si só, não resolve o problema do monitoramento em larga escala: a análise visual de ortomosaicos por especialistas torna-se inviável quando a área de estudo se amplia para dezenas ou centenas de hectares.

Este trabalho aborda o problema da detecção e segmentação de copas de *Cecropia pachystachya* (embaúba) em um ortomosaico de VANT por meio de **duas frentes complementares**:

- **Parte I — Visão Computacional Clássica.** Um pipeline sem aprendizado profundo, baseado em segmentação por espaço de cor HSV, operações morfológicas, extração de contornos e filtros geométricos. É interpretável, auditável e computacionalmente leve, servindo como *baseline* e como primeira estimativa da distribuição espacial da espécie.
- **Parte II — Redes Neurais (SAM 3 + YOLOv8).** Um pipeline semi-automatizado que integra o modelo fundacional de segmentação Segment Anything Model 3 (SAM 3) com o detector YOLOv8, reduzindo o esforço de anotação manual por meio de uma estratégia de “curadoria por exclusão” e permitindo detecção e segmentação individuais das copas em escala.

Ambas as frentes operam sobre o **mesmo ortomosaico** do experimento MataDIV (mesma área, mesmo sistema de referência e mesma resolução espacial), o que permite comparar diretamente as duas estratégias. A abordagem clássica evidencia até onde é possível chegar com regras explícitas de cor e forma, enquanto a abordagem neural mostra os ganhos e os custos de incorporar aprendizado de máquina ao problema.

A espécie-alvo, *Cecropia pachystachya* Trécul (Urticaceae), é uma árvore pioneira de rápido crescimento, amplamente distribuída nas florestas tropicais e subtropicais da região Neotropical (Berg et al., 2005). Ecologicamente, sua presença e abundância estão associadas à intensidade de perturbações florestais, o que a estabelece como indicadora do estágio de regeneração de uma área (Guitet et al., 2018). Além disso, apresenta características morfológicas que favorecem sua detecção em imagens aéreas — folhas grandes e palma-

tilobadas, coloração verde-prateada na face abaxial e copa de arquitetura umbeliforme distinta das demais espécies do dossel (Carvalho, 2008). A conjunção entre relevância ecológica e distinguibilidade visual motivou sua escolha como modelo biológico para este estudo.

2 Objetivos

Objetivo geral

Desenvolver e avaliar metodologias para detecção e segmentação individual de copas de *Cecropia pachystachya* em ortomosaico de VANT, comparando uma abordagem de visão computacional clássica com uma abordagem de redes neurais que integra o SAM 3 e o YOLOv8, com ênfase na redução do esforço manual.

Objetivos específicos

- Construir um pipeline clássico interpretável (HSV, morfologia, contornos e filtros geométricos) e avaliá-lo quanto a precisão, recall e custo computacional.
- Desenvolver um pipeline semi-automatizado de detecção e segmentação com SAM 3, minimizando as etapas manuais de criação do dataset e treinamento do modelo.
- Avaliar o desempenho do pipeline neural na detecção e segmentação de copas de *C. pachystachya* em diferentes cenários de composição florestal do experimento MataDIV.
- Discutir a replicabilidade das duas abordagens para a detecção e segmentação de outras espécies arbóreas.

3 Área de Estudo e Coleta de Dados

3.1 Área de estudo

O estudo foi conduzido no experimento MataDIV (Mata Atlântica Diversidade), localizado na Estação Experimental de Ciências Florestais de Itatinga, pertencente à Escola Superior de Agricultura “Luiz de Queiroz” (ESALQ/USP), no município de Itatinga, São Paulo, Brasil (23°06’S, 48°39’W). O MataDIV é um experimento de diversidade arbórea e funcionamento ecossistêmico (BEF) integrado à rede global TreeDivNet, plantado em 2019 em uma área de antigo talhão comercial de *Eucalyptus* (Verheyen et al., 2016; Paquette et al., 2018).

O experimento manipula três variáveis (riqueza de espécies, fertilização e disponibilidade hídrica) em 144 parcelas experimentais que ocupam aproximadamente 8 hectares. Cada parcela possui dimensões de 20 m × 23 m e contém 100 árvores plantadas em espaçamento de 2,3 m, totalizando cerca de 14.400 indivíduos. As composições combinam seis espécies nativas de estratégias ecológicas contrastantes em 12 estratos distintos — de monoculturas a uma composição de alta diversidade com 20 espécies. A *Cecropia pachystachya* está presente em cinco dessas composições, com densidade que varia de 100 indivíduos por parcela na monocultura a aproximadamente 5 indivíduos nas parcelas de alta diversidade.

Essa variedade torna o MataDIV particularmente adequado para avaliar a robustez das metodologias sob diferentes condições de complexidade do dossel.

3.2 Coleta de dados e ortomosaico

O sobrevoo foi realizado em 13 de março de 2026 com o VANT DJI Matrice 4T, equipado com câmera RGB wide (sensor CMOS 1/1.3", 48 MP, distância focal equivalente a 24 mm, campo de visão de 82°). A coleta ocorreu a 23 m acima do nível do solo, com sobreposição frontal e lateral de 80%, resultando em uma resolução espacial no solo (GSD) de aproximadamente 0,85 cm/pixel. As imagens foram processadas por fotogrametria digital no software Agisoft Metashape, gerando um ortomosaico georreferenciado de 48.264×47.029 pixels, com quatro bandas espectrais (R, G, B e alfa), aproximadamente 8,46 GB em GeoTIFF, projetado em SIRGAS 2000 / UTM zona 22S (EPSG:31982).

Esse único ortomosaico é a base de dados comum às duas frentes deste trabalho. A diferença entre elas está na forma como o ortomosaico é recortado em *tiles* e nos artefatos de referência utilizados, descritos no início de cada parte.

Parte I

Solução com Visão Computacional Clássica

4 Dataset (Recorte para a Abordagem Clássica)

Para a abordagem clássica, o ortomosaico (Seção 3.2) foi dividido em *tiles* JPEG de resolução fixa. A Tabela 1 resume as características desse recorte.

Tabela 1: Características do dataset da abordagem clássica.

Parâmetro	Valor
Total de tiles	992
Resolução por tile	2048×2048 px
Sobreposição entre tiles	512 px (25%)
Sistema de referência (CRS)	EPSG:31982 (UTM Zona 22S)
Resolução espacial	$\approx 0,00848$ u/px
Tamanho aproximado em disco (<code>data/tiles</code>)	899,0 MB
Tiles pretos (fora da área mapeada)	229 (ignorados automaticamente)
Tiles efetivamente processados	361

Os tiles completamente pretos correspondem a regiões fora dos limites do mosaico (padding do recorte) e são descartados antes do processamento com base na intensidade média da imagem.

O conjunto de validação fica em `data/validacao/`, com uma subpasta por imagem revisada (`<nome>.jpg`, `<nome>.json`, `<nome>_vis.png`). Atualmente há 18 JSONs de validação, todos revisados manualmente. Cada JSON armazena a saída do detector em `embaubas`, os índices marcados como falso positivo em `falsos_positivos` e caixas `faltantes` para copas visíveis que não foram detectadas.

5 Pipeline de Detecção Clássico

O pipeline foi organizado como uma sequência de etapas clássicas de visão computacional porque a embaúba possui um sinal visual relativamente interpretável no mosaico: a copa tende a aparecer em uma faixa de verde claro/amarelado e, após a segmentação por cor, pode ser tratada como uma região conectada. A divisão em cor, morfologia, contornos e filtros geométricos torna o processo auditável: cada decisão intermediária pode ser visualizada e ajustada sem depender de aprendizado profundo.

Essa escolha também responde às principais dificuldades do problema. A segmentação HSV separa candidatos pela cor; as operações morfológicas reduzem falhas internas e ruídos; os contornos transformam a máscara em objetos mensuráveis; e os filtros finais removem regiões incompatíveis com copas plausíveis. A Figura 1 mostra a visão geral do passo a passo em um tile amostrado.




Figura 1: Visualização das imagens de inspeção do pipeline sobre `tile_0634.jpg`. Da esquerda para a direita, de cima para baixo: imagem original, blur gaussiano, canal H, canal S, canal V, máscara bruta, máscara limpa e resultado final.

5.1 Etapa 1 - Suavização (Gaussian Blur)

Pipeline —

2. Gaussian Blur (9x9)



Figura 2: Imagem suavizada com filtro gaussiano.

Motivação. A primeira etapa reduz ruído fino de textura e pequenas variações locais causadas por compressão JPEG, sombra e detalhes das folhas. Sem essa suavização, pixels isolados podem cair dentro da faixa HSV e gerar manchas espúrias na máscara.

A imagem original em BGR é suavizada com um filtro gaussiano de kernel 9×9 e $\sigma = 0$ (calculado automaticamente a partir do tamanho do kernel). O filtro preserva a estrutura geral das copas, mas atenua detalhes muito pequenos.

5.2 Etapa 2 - Conversão BGR $\rightarrow$ HSV

e_0634.jpg)




Figura 3: Canais HSV extraídos após a suavização.

Motivação. A conversão para HSV separa matiz, saturação e brilho. Isso é útil porque a cor característica da copa é descrita melhor pela matiz do que pelos valores RGB brutos, que variam mais com iluminação e sombra.

A imagem suavizada é convertida para o espaço de cor HSV (*Hue*, *Saturation*, *Value*). Esse espaço é mais robusto a variações de iluminação do que RGB, pois separa a informação de matiz da luminosidade.

5.3 Etapa 3 - Limiarização por Cor




Figura 4: Máscara bruta produzida pela faixa HSV.

Motivação. A limiarização por cor é o ponto de entrada do detector: ela transforma a imagem em uma hipótese binária de onde pode haver embaúba. A faixa foi escolhida para privilegiar o verde-claro das copas, sabendo que outras espécies com cor parecida também podem aparecer como candidatos.

A segmentação é feita com um limiar fixo definido empiricamente para a tonalidade verde-clara característica da folhagem de *Cecropia*:

$$\text{HSV}_{lower} = [44, 144, 104], \quad \text{HSV}_{upper} = [58, 231, 203] \quad (1)$$

Pixels cujos valores HSV estão dentro desse intervalo recebem valor 255 na *máscara bruta*; os demais recebem 0.

5.4 Etapa 4 - Fechamento Morfológico




Figura 5: Máscara após operações morfológicas, com regiões internas mais coesas.

Motivação. A copa de uma árvore raramente aparece como uma mancha compacta perfeita: há sombras, pequenas aberturas e variações internas. O fechamento conecta fragmentos próximos e fecha buracos, permitindo que uma copa seja tratada como uma região única.

A máscara bruta contém fragmentos desconectados correspondentes a partes visíveis da copa entre as folhas. A operação de fechamento morfológico com um elemento estruturante elíptico de 25×25 pixels preenche essas lacunas, unindo fragmentos próximos em regiões coesas que representam copas individuais.

5.5 Etapa 5 - Abertura Morfológica




Figura 6: Máscara limpa após remoção de pequenos componentes.

Motivação. Depois do fechamento, ainda podem restar pequenos respingos ativados pela faixa HSV. A abertura remove esses componentes menores e diminui o número de candidatos sem destruir regiões maiores compatíveis com copas.

Após o fechamento, pequenas regiões isoladas que não correspondem a copas reais são eliminadas pela abertura morfológica com elemento elíptico de 9×9 pixels. Essa etapa remove ativações espúrias de pequena área sem afetar as regiões maiores já consolidadas pelo fechamento.

5.6 Etapa 6 - Detecção de Contornos



Figura 7: Regiões conectadas convertidas em candidatos desenhados sobre a imagem.

Motivação. A máscara binária precisa ser convertida em objetos geométricos para que cada região possa ser medida. A detecção de contornos fornece área, perímetro e caixa delimitadora para as etapas de filtragem.

Os contornos externos da máscara limpa são extraídos com `cv2.findContours` usando `RETR_EXTERNAL` e `CHAIN_APPROX_SIMPLE`. Essa escolha privilegia os blobs principais da segmentação e reduz a complexidade dos contornos sem afetar a área estimada.

5.7 Etapa 7 - Filtragem por Área Mínima




Figura 8: Candidatos remanescentes após descarte de regiões pequenas.

Motivação. Regiões muito pequenas tendem a ser ruído, bordas de outras plantas ou pequenos agrupamentos de folhas, não copas completas. O filtro de área mínima reduz esses falsos candidatos antes da regra final.

Contornos com área inferior a 10.000 px^2 são descartados. Esse threshold elimina manchas pequenas e ruído residual que ainda sobreviveram às etapas morfológicas, mantendo apenas regiões compatíveis com copas.

5.8 Etapa 8 - Filtro Final de Embaúba




Figura 9: Resultado final depois dos filtros de tamanho, circularidade e solidez.

Motivação. A segmentação por cor é propositalmente permissiva. O filtro final usa forma e tamanho para rejeitar parte dos falsos positivos, como centros de palmeiras e blobs fundidos grandes demais, mantendo regiões mais plausíveis como embaúba.

Sobre os candidatos restantes, aplica-se uma regra geométrica final: um contorno é aceito como embaúba quando sua área é maior ou igual a 33.798 px^2 ou sua circularidade é menor ou igual a $0,1551$, desde que a área não ultrapasse 600.000 px^2 e a solidez seja pelo menos $0,48$. A primeira condição favorece copas grandes; a segunda captura formas menos circulares; o teto de área remove blobs fundidos gigantes; e a solidez evita regiões excessivamente fragmentadas.

5.9 Etapa 9 - Convex Hull




Figura 10: Contorno final representado pelo fecho convexo da região detectada.

Motivação. O contorno segmentado pode ter reentrâncias por sombra, lacunas ou mistura com vegetação vizinha. O fecho convexo produz uma forma mais estável para visualização e exportação dos limites da copa.

Para cada contorno aprovado, calcula-se o fecho convexo (*convex hull*). Isso regulariza a forma da detecção, eliminando reentrâncias causadas por sombras ou sobreposição de folhas, e aproxima melhor o perímetro circular da *Cecropia* vista de cima. O hull é desenhado sobre a imagem original para visualização.

6 Resultados da Abordagem Clássica

6.1 Estatísticas Gerais

A Tabela 2 apresenta as métricas consolidadas do processamento completo do dataset.

Tabela 2: Estatísticas do processamento completo (361 tiles).

Métrica	Valor
Tiles processados	361
Tiles pretos ignorados	229
Tiles com ≥ 1 detecção	311 (86,1%)
Total de detecções	1.218
Detecções por tile	$3,37 \pm 2,78$
Área total estimada	8.365,61 u ²
Área média por região	95.522 px ²
Área máxima por região	599.406 px ²
Cobertura HSV média	14,891%
Tempo total	89,0 s
Tempo médio por tile	$151,9 \pm 57,3$ ms
Memória média por tile	63,5 MB
Memória de pico por tile	64,4 MB

6.2 Distribuição de Detecções por Tile




Figura 11: Histograma da distribuição do número de detecções por tile.

A distribuição (Figura 11) é assimétrica à direita: a maioria dos tiles apresenta poucas detecções, enquanto um pequeno número de tiles concentra muitas detecções, sugerindo que a *Cecropia* ocorre em manchas densas em certas regiões do mosaico.

6.3 Distribuição das Áreas de Detecção




Figura 12: Histograma das áreas das regiões detectadas (em px^2).

A grande maioria das detecções (Figura 12) possui área próxima ao limiar mínimo de 10.000 px^2 , com uma cauda longa de regiões muito grandes. Regiões extremamente grandes indicam provavelmente agrupamentos de vegetação com cor similar fundidos pelo fechamento morfológico, e não copas individuais.

6.4 Cobertura HSV por Tile




Figura 13: Percentual de cobertura HSV por tile (pixels dentro da faixa HSV definida, após morfologia).

A cobertura HSV mede a fração do tile ativada pela faixa de cor após as operações morfológicas. Valores altos indicam tiles com muita vegetação dentro da faixa espectral da embaúba, mas não significam automaticamente muitas copas: também podem refletir vegetação semelhante, sombras e regiões fundidas.

6.5 Top 10 Tiles com Mais Detecções




Figura 14: Top 10 tiles por número de detecções.

Tabela 3: Top 10 tiles por número de detecções.

Tile	Detecções	Área (px ²)	Área (u ²)	Cobertura
tile_0634.jpg	13	1.027.336	73,87	25,04%
tile_0666.jpg	13	1.271.576	91,43	30,57%
tile_0633.jpg	12	796.373	57,26	20,03%
tile_0488.jpg	11	1.224.788	88,07	29,33%
tile_0634.jpg	11	964.494	69,35	23,86%
tile_0753.jpg	11	668.577	48,07	20,78%
tile_0875.jpg	11	819.124	58,90	21,62%
tile_0435.jpg	10	966.308	69,48	24,23%
tile_0591.jpg	10	1.072.664	77,13	29,15%
tile_0721.jpg	10	794.666	57,14	25,49%

6.6 Validação Manual

A validação compara a saída final do detector com a revisão manual de 18 tiles. Em cada JSON revisado, as detecções confirmadas contam como verdadeiros positivos, os índices marcados em **falsos_positivos** contam como falsos positivos e as caixas **faltantes** contam como falsos negativos.

Tabela 4: Resumo da validação manual (abordagem clássica).

Métrica	Valor
Tiles revisados	18/18
Verdadeiros positivos (TP)	33
Falsos positivos (FP)	6
Falsos negativos / faltantes (FN)	30
Precisão	84,6%
Recall	52,4%
F1	64,7%

A precisão de 84,6% indica que a maior parte das regiões detectadas corresponde a embaúba na amostra revisada. O recall de 52,4% mostra que o método ainda perde uma fração relevante das copas reais, principalmente quando a segmentação HSV não produz um candidato inicial ou quando a copa aparece com iluminação e cor fora da faixa definida.

6.7 Desempenho Computacional




Figura 15: Métricas de desempenho computacional do pipeline clássico.

O tempo médio de 151,9 ms por tile demonstra que o pipeline clássico permanece eficiente para inspeção em lote. O total de 361 tiles válidos foi processado em 89,0 s, com uso de memória estável (~ 64 MB/tile), reflexo das operações matriciais do OpenCV que mantêm apenas a imagem corrente em memória. O passo a passo foi amostrado em tiles selecionados, reduzindo o custo de geração das figuras.

7 Interpretação e Limitações da Abordagem Clássica

7.1 Alta taxa de tiles com detecções (86,1%)

O fato de 311 em 361 tiles apresentarem ao menos uma detecção sugere cobertura ampla do mosaico por vegetação dentro da faixa HSV definida. Entretanto, esse número deve ser interpretado com cautela: o filtro HSV não é específico para *Cecropia* — outras espécies com folhagem de tonalidade verde-clara similar também ativam a máscara.

7.2 Falsos positivos por confusão espectral

A inspeção visual do `tile_0634.jpg` (Figura 1) evidencia o principal problema do método: a segmentação HSV não distingue *Cecropia* de outras plantas com tom similar. No canal H (matiz), praticamente toda a vegetação do tile cai dentro do intervalo $[44, 58]$, fazendo a máscara bruta ativar de forma generalizada. Após as operações morfológicas, grandes blobs são formados fundindo múltiplas espécies, e cada blob é contado como uma detecção.

As causas raízes são:

- **Sobreposição espectral:** o intervalo HSV da *Cecropia* não é exclusivo; vegetação secundária densa tem cor similar.
- **Ausência de informação de forma:** a *Cecropia* tem copa arredondada com padrão radial característico, mas o pipeline não explora textura nem geometria.

- **Fusão morfológica:** o CLOSE com kernel de 25 px une copas próximas em uma única região, inflando o número de detecções por área.

7.3 Regiões de área muito grande

A área máxima atual foi limitada a 599.406 px² pelo teto de 600.000 px² no filtro final. Esse teto remove os maiores blobs fundidos que apareciam em versões anteriores do pipeline, mas ainda permite regiões grandes o suficiente para representar copas extensas ou agrupamentos próximos. Portanto, o limiar de área mínima elimina ruído pequeno, enquanto o limiar de área máxima reduz agregações incompatíveis com uma copa individual.

7.4 Leitura da Validação

A validação final mostra 33 verdadeiros positivos, 6 falsos positivos e 30 falsos negativos. A precisão de 84,6% indica que o filtro final de tamanho, circularidade e solidez reduziu bem os falsos positivos na amostra revisada. O recall de 52,4%, por outro lado, mostra que muitas copas reais ainda não entram na saída final, principalmente por dependerem de uma faixa HSV fixa.

Parte II

Solução com Redes Neurais (SAM 3 + YOLOv8)

A segunda frente do trabalho substitui as regras explícitas de cor e forma por um pipeline semi-automatizado de aprendizado de máquina. Ele integra o modelo fundacional de segmentação SAM 3 — usado tanto na geração do dataset quanto na segmentação final das copas — com o detector YOLOv8, responsável pela localização dos indivíduos. A ideia central é reduzir ao máximo o esforço de anotação manual, que costuma ser a etapa mais custosa em abordagens supervisionadas.

8 Metodologia da Abordagem Neural

A metodologia proposta é composta por seis etapas sequenciais (Figura 16): (1) geração do dataset com SAM 3 *text prompt*, (2) divisão espacial do dataset, (3) correção semi-automatizada das anotações, (4) treinamento do YOLOv8x, (5) inferência e pós-processamento e (6) segmentação das copas com SAM 3 por *prompt* geométrico.

[Pendente: Figura — Fluxograma geral do pipeline semi-automatizado com as seis etapas.]

Figura 16: Fluxograma geral do pipeline semi-automatizado (SAM 3 + YOLOv8).

8.1 Contexto: SAM 3 e curadoria por exclusão

Avanços recentes em modelos fundacionais de segmentação oferecem uma alternativa à anotação manual. O Segment Anything Model (SAM), desenvolvido pela Meta AI, é treinado em um conjunto de mais de um bilhão de máscaras, sendo capaz de segmentar objetos em domínios para os quais nunca foi especificamente treinado, como ortomosaicos de VANT (Kirillov et al., 2023). Sua terceira versão, o SAM 3, introduziu a segmentação a partir de *prompts* textuais: ao receber a palavra “tree”, por exemplo, o modelo delinea exclusivamente as copas de árvores presentes na imagem.

Essa funcionalidade permite repensar a geração de dados de treinamento. Em vez de desenhar manualmente cada anotação, o pesquisador utiliza o SAM 3 para gerar candidatos de segmentação e, em seguida, realiza uma **curadoria por exclusão**, removendo apenas os segmentos que não correspondem à espécie de interesse. O esforço humano deixa de ser criar anotações do zero e passa a ser filtrar um conjunto pré-existente — tarefa significativamente mais rápida e que demanda apenas o reconhecimento da espécie-alvo.

8.2 Geração do dataset de treinamento

O ortomosaico georreferenciado foi recortado em tiles de 4.096×4.096 pixels com sobreposição de 1.024 pixels e submetido ao SAM 3 com o *prompt* textual “tree”. O modelo segmentou automaticamente as copas presentes em cada tile, gerando 4.569 polígonos referentes a diversas espécies. Como a área coberta pelo ortomosaico ultrapassa os limites do experimento MataDIV, parte dos polígonos corresponde a indivíduos no entorno da área experimental.

Os polígonos foram carregados no ambiente SIG (QGIS), onde o operador realizou a curadoria por exclusão: cada polígono foi avaliado visualmente e os que não correspondiam a *C. pachystachya* foram removidos. Ao final, restaram **1.109 máscaras** da espécie-alvo, das quais 975 dentro dos limites do MataDIV e 134 no entorno. A partir das máscaras curadas, caixas delimitadoras (*bounding boxes*) foram geradas automaticamente no QGIS pela ferramenta de geometria envolvente, sem intervenção manual no traçado.

Essas máscaras cumprem dupla função: servem de base para o dataset de detecção (via *bounding boxes*) e, simultaneamente, constituem o produto final de segmentação para os indivíduos identificados nesta fase. As 975 cecropias segmentadas dentro do MataDIV já possuem suas copas delineadas e não necessitam de segmentação adicional.

Para o treinamento do detector, o ortomosaico foi recortado em tiles de 896×896 pixels com sobreposição de 50%. O tamanho do tile foi definido com base na maior copa de *Cecropia* identificada, garantindo que nenhum tile fosse menor que uma copa inteira e que o modelo recebesse contexto espacial suficiente. A sobreposição de 50% faz um mesmo indivíduo aparecer em múltiplos tiles em posições distintas, funcionando como aumento de dados implícito. Dessa forma, os 1.109 indivíduos únicos geraram **7.488 instâncias** de treinamento (fator de repetição médio de 6,8 vezes por indivíduo). As coordenadas dos polígonos foram convertidas para o formato de anotação YOLO, com vértices normalizados entre 0 e 1.

8.3 Divisão espacial do dataset

O dataset foi dividido em treinamento (70%), validação (15%) e teste (15%). Em imagens de sensoriamento remoto com sobreposição entre tiles, a amostragem aleatória simples pode causar *vazamento de dados* (*data leakage*), com um mesmo indivíduo presente simultaneamente em treinamento e teste, inflando artificialmente as métricas (Roberts et al., 2017; Kattenborn et al., 2022). Para evitar isso, foi implementado um algoritmo de divisão baseado em clusterização espacial, em quatro etapas:

1. Cada anotação é associada ao tile cujo centroides está mais próximo, estabelecendo uma relação unívoca entre anotação e tile.
2. Anotações que intersectam mais de um tile com sobreposição superior a 20% da área da anotação vinculam os tiles envolvidos, pois compartilham o mesmo indivíduo.
3. Os vínculos entre tiles formam um grafo, no qual componentes conexos são identificados por busca em largura (BFS), definindo *clusters* de tiles que devem pertencer ao mesmo conjunto.
4. Os *clusters* são distribuídos entre treinamento, validação e teste por otimização estocástica de Monte Carlo (1.000 iterações), minimizando o erro quadrático médio (MSE) entre as proporções obtidas e as metas de 70/15/15.

8.4 Correção semi-automatizada das anotações

Um primeiro ciclo de treinamento revelou, na matriz de confusão, que parte dos falsos negativos correspondia a indivíduos reais de *C. pachystachya* presentes nas imagens, porém ausentes nas anotações geradas pelo SAM 3. Para corrigir isso, o modelo treinado foi aplicado sobre os conjuntos de validação e teste, e cada detecção foi comparada às anotações existentes por Intersecção sobre União (IoU). Detecções com IoU inferior a 0,5 em relação a qualquer anotação foram consideradas potenciais indivíduos não anotados. Para cada imagem, foi gerada uma visualização com as anotações existentes em verde e as detecções sem correspondência em vermelho (Figura 17), permitindo ao operador avaliar cada caso.

[Pendente: Figura — Imagem de teste com anotações existentes (verde) e detecções sem correspondência (vermelho).]

Figura 17: Procedimento semi-automatizado de complementação de anotações.

No conjunto de teste, das 163 detecções sem correspondência, 157 foram confirmadas como cecropias genuínas e apenas 6 descartadas como falsos positivos. No conjunto de validação, 144 novas anotações foram incorporadas e 2 descartadas. Após o *merge* das novas anotações, o modelo foi retreinado com os conjuntos corrigidos. A correção foi aplicada apenas aos conjuntos de validação e teste (cerca de 160 imagens cada), por serem menores; o mesmo procedimento pode ser estendido ao conjunto de treinamento (776 imagens) para melhorar ainda mais as métricas. A Tabela 5 apresenta a estrutura final do dataset.

Tabela 5: Estrutura final do dataset da abordagem neural.

Conjunto	Imagens	Instâncias (original)	Instâncias (corrigido)
Treinamento	776	6.300	6.300 (sem alteração)
Validação	167	543	687 (+144)
Teste	166	645	799 (+154)
Total	1.109	7.488	7.786

8.5 Treinamento do modelo de detecção

A detecção foi conduzida com o YOLOv8x, a variante de maior capacidade da família YOLOv8, implementada via biblioteca Ultralytics (Jocher et al., 2023). Optou-se pela versão de detecção (e não a de segmentação de instâncias), uma vez que o SAM 3 é responsável pela delimitação das copas nas etapas inicial e final; ao YOLO cabe exclusivamente a localização dos indivíduos por caixas delimitadoras.

Como o desempenho de modelos de *deep learning* é sensível à configuração dos hiperparâmetros, adotou-se uma otimização bayesiana com o *framework* Optuna (Akiba et al., 2019) e o amostrador TPE (*Tree-structured Parzen Estimator*). O espaço de busca contemplou 21 hiperparâmetros em três categorias: parâmetros do otimizador, pesos da função de perda e parâmetros de aumento de dados (Tabela 6). A otimização foi conduzida ao longo de 30 tentativas com 20 épocas cada, utilizando o mAP50 no conjunto de validação como métrica de orientação, com *batch size* 8 e imagem de 896×896 .

Tabela 6: Espaço de busca dos hiperparâmetros otimizados.

Hiperparâmetro	Funcionalidade	Inf.	Sup.
<i>Categoria: Hiperparâmetros do otimizador</i>			
Freeze Layers	Número de camadas sem atualização de pesos	0	21
Learning Rate (lr0)	Taxa de aprendizagem inicial	1e-05	0,01
Final LR Factor (lrf)	Fator de decaimento final do learning rate	0,01	1,0
Momentum	Inércia do otimizador	0,6	0,98
Weight Decay	Penaliza pesos grandes (evita overfitting)	0,0001	0,001
Warmup Epochs	Épocas iniciais com learning rate crescente	0	5
<i>Categoria: Pesos da função de perda</i>			
Box Loss Weight	Peso da perda de localização da bounding box	0,02	0,2
Class Loss Weight	Peso da perda de classificação	0,2	4,0
<i>Categoria: Aumento de dados (data augmentation)</i>			
HSV Hue Aug.	Alteração da tonalidade da imagem	0	0,1
HSV Sat. Aug.	Alteração da saturação da imagem	0	0,9
HSV Val. Aug.	Alteração do brilho da imagem	0	0,9
Rotation (deg)	Transformação geométrica de rotação	0	45
Translation	Transformação geométrica de translação	0	0,9
Scale Aug.	Transformação geométrica de escala	0	0,9
Shear (deg)	Transformação geométrica de cisalhamento	0	10
Perspective	Transformação geométrica de perspectiva	0	0,001
Flip Up-Down	Espelhamento vertical da imagem	0	1
Flip Left-Right	Espelhamento horizontal da imagem	0	1
Mosaic	Combinação de 4 imagens em 1	0	1
MixUp	Sobreposição de duas imagens com transparência	0	1
Copy-Paste	Cópia de segmentos de uma imagem para outra	0	1

Além da seleção dos melhores valores, os resultados das 30 tentativas foram usados como entrada para um regressor *Random Forest* de 500 árvores, cuja importância de cada hiperparâmetro foi estimada pela Redução Média da Impureza (*Mean Decrease Impurity*), permitindo compreender quais variáveis mais influenciam o desempenho. Concluída a otimização, o treinamento final foi realizado com 500 épocas, imagem de 896 pixels, *batch size* 8 e otimizador AdamW, adotando os hiperparâmetros da melhor tentativa.

8.6 Inferência e pós-processamento

O modelo treinado foi aplicado sobre o ortomosaico completo, recortado em tiles de 896×896 pixels com sobreposição de 50%. Para detectar adequadamente indivíduos nas bordas entre tiles, a inferência foi conduzida em duas rodadas: uma com os tiles na grade regular e outra com tiles deslocados em meio passo (offset de 50%), de modo que regiões de borda na primeira rodada ficassem centralizadas na segunda.

Detecções a menos de 10 pixels da borda do tile foram descartadas. Em seguida, as detecções das duas rodadas foram combinadas e submetidas a remoção de duplicatas: pares com sobreposição espacial superior a 10% da menor área foram identificados e, em cada par, a detecção de menor confiança foi descartada. Após a deduplicação, foram aplicadas regras de filtragem: descarte de detecções com confiança inferior a 0,65 ou área inferior a $1,75 \text{ m}^2$ ou superior a 40 m^2 , além da exclusão de detecções fora dos limites do MataDIV.

As detecções resultantes foram cruzadas espacialmente com as máscaras do SAM 3 (Seção da geração do dataset), classificando os indivíduos em três categorias: (i) detectados pelo YOLO e já com máscara prévia do SAM 3; (ii) detectados exclusivamente pelo YOLO, sem máscara prévia; e (iii) segmentados pelo SAM 3 na etapa inicial, mas não detectados pelo YOLO. Os indivíduos das categorias (i) e (iii) já dispõem de segmentação; os da categoria (ii) seguem para a segmentação refinada descrita a seguir.

8.7 Segmentação das copas com SAM 3 por prompt geométrico

Para segmentar as copas dos indivíduos detectados exclusivamente pelo YOLO, utilizou-se novamente o SAM 3, agora com *prompt* geométrico: a *bounding box* detectada é fornecida como entrada para orientar a segmentação. Recorta-se do ortomosaico uma região ao redor de cada caixa, com uma margem de expansão (*padding*) que fornece contexto espacial, e o recorte georreferenciado é submetido ao SAM 3. Quando o modelo produz múltiplas máscaras candidatas, adota-se um critério de seleção central (máscara cujo centroide está mais próximo do centro do recorte). As máscaras selecionadas são convertidas em polígonos vetoriais georreferenciados e submetidas a operações de limpeza morfológica. Os parâmetros adotados estão na Tabela 7.

Tabela 7: Parâmetros da segmentação por prompt geométrico com SAM 3.

Parâmetro	Valor adotado
Padding ao redor da bbox	300 cm
Área mínima do polígono	$0,3 \text{ m}^2$
Confiança do SAM 3	0,25
Estratégia de seleção	Central (centroide mais próximo do centro)

Os polígonos resultantes foram integrados ao conjunto de máscaras da segmentação inicial por *prompt* textual, compondo o mapeamento final de copas de *C. pachystachya* na área do MataDIV.

8.8 Métricas de avaliação

O desempenho do detector foi avaliado no conjunto de teste, classificando cada detecção como Verdadeiro Positivo (VP), Falso Positivo (FP) ou Falso Negativo (FN). A correspondência espacial entre a caixa predita e a anotação de referência é medida pela Intersecção sobre União (IoU), com limiar de 0,5:

$$\text{IoU} = \frac{\text{Área da Intersecção}}{\text{Área da União}} \quad (2)$$

A partir da contagem de VP, FP e FN, calculam-se:

$$P = \frac{VP}{VP + FP}, \quad R = \frac{VP}{VP + FN}, \quad F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad (3)$$

A Average Precision (AP) é a área sob a curva Precision-Recall, $AP = \int_0^1 P(R) dR$. Como há apenas uma classe (*Cecropia pachystachya*), o mAP equivale à própria AP; manteve-se a notação mAP50 por ser padrão na biblioteca Ultralytics. Utilizou-se também o mAP50-95, média da AP em dez limiares de IoU igualmente espaçados entre 0,5 e 0,95, que penaliza detecções com baixa sobreposição espacial e exige maior precisão na localização.

9 Resultados da Abordagem Neural

[Pendente: Esta seção depende dos resultados quantitativos do pipeline SAM 3 + YOLOv8, que ainda não constam no material fornecido (o relatório da frente neural termina em “Métricas de avaliação”). Preencher com: métricas de detecção no conjunto de teste (Precisão, Recall, F1, mAP50, mAP50-95), curvas Precision-Recall e de treinamento, importância dos hiperparâmetros (Random Forest / Mean Decrease Impurity), contagem final de indivíduos mapeados por categoria (i/ii/iii) e figuras qualitativas de detecção e segmentação sobre o ortomosaico.]

Parte III

Síntese Comparativa

10 Discussão Comparativa

As duas abordagens atacam o mesmo problema — mapear copas de *Cecropia pachystachya* no ortomosaico do MataDIV — por caminhos opostos em termos de premissas, custo e capacidade de generalização. A Tabela 8 resume as principais diferenças.

Tabela 8: Comparação entre as duas abordagens.

Aspecto	Visão Clássica (HSV)	Redes Neurais (SAM 3 + YOLOv8)
Sinal explorado	Cor (faixa HSV) e forma (área, circularidade, solidez)	Padrões visuais aprendidos (cor, textura, forma)
Anotação	Não requer (revisão manual só para validação)	Curadoria por exclusão sobre máscaras do SAM 3
Interpretabilidade	Alta: cada etapa é auditável	Baixa: decisão distribuída nos pesos da rede
Custo computacional	Baixo (~ 152 ms/tile, CPU)	Alto (GPU; otimização + treino de 500 épocas)
Segmentação de copa	Fecho convexo aproximado	Máscara do SAM 3 (polígono refinado)
Discriminação de espécie	Fraca (confusão espectral)	Potencialmente alta (aprende contexto)
Resultado	P 84,6% / R 52,4% / F1 64,7%	<i>[Pendente: a definir]</i>

A abordagem clássica é leve, transparente e não exige anotação, mas esbarra na confusão espectral: como diversas espécies caem na mesma faixa de verde, o recall fica limitado (52,4%) e há fusão de copas próximas. A abordagem neural procura justamente superar essa limitação, aprendendo padrões visuais que vão além da cor e delegando a segmentação fina ao SAM 3. Em contrapartida, exige infraestrutura de GPU, um ciclo de treinamento longo e uma etapa (ainda que reduzida) de curadoria.

Vale notar que as duas frentes se complementam metodologicamente: o pipeline clássico funciona como *baseline* interpretável e como ferramenta rápida de inspeção, enquanto o pipeline neural busca precisão e generalização para outras espécies. A estratégia de curadoria por exclusão do SAM 3, em particular, reduz drasticamente a barreira de entrada que normalmente inviabiliza o uso de aprendizado profundo em contextos botânicos.

11 Conclusões

Este trabalho apresentou duas soluções complementares para a detecção e segmentação de copas de *Cecropia pachystachya* sobre um mesmo ortomosaico de VANT do experimento MataDIV.

A **abordagem clássica** (Parte I) demonstrou ser viável para uma primeira estimativa da distribuição espacial da espécie: é eficiente, escalável por paralelismo e produz resultados interpretáveis pelas visualizações passo a passo. Foram detectadas 1.218 regiões em 361 tiles válidos, e a validação manual atingiu 84,6% de precisão e 52,4% de recall. O filtro final reduz fortemente os falsos positivos, mas o recall limitado revela que a dependência de uma faixa HSV fixa deixa escapar copas reais.

A **abordagem neural** (Parte II) propõe um pipeline semi-automatizado que integra o SAM 3 e o YOLOv8, com destaque para a curadoria por exclusão, que reduz o esforço de anotação, e para a divisão espacial do dataset, que evita vazamento de dados. A metodologia está completa e descrita em detalhe; *[Pendente: os resultados quantitativos da frente neural ainda precisam ser incorporados a partir do material final dessa etapa.]*

Trabalhos futuros

1. **Abordagem clássica:** refinar o intervalo HSV a partir de pixels anotados, consolidar detecções entre tiles para evitar contagens repetidas, recalibrar os filtros geométricos e incorporar descritores de textura (LBP, Haralick) para explorar a estrutura radial das folhas.
2. **Abordagem neural:** concluir a avaliação quantitativa, estender a correção semi-automatizada ao conjunto de treinamento e testar a replicabilidade do pipeline para outras espécies arbóreas.
3. **Integração:** usar o pipeline clássico como pré-filtro rápido e o neural como refinamento, ou comparar as duas saídas para estimar incerteza no mapeamento final.